Faz 0: geri besleme kısıtlı sequence modellerin fizibilitesi

Soru. FPGA'nin boş duran logic kapasitesini kullanarak, döngüsü çok kısa olan öğrenilmiş bir dijital sekans makinesi, aritmetik ağırlıklı bir dil modelinin yerini tutabilir mi? Faz 0 bu fikrin denemeye değip değmediğini ölçer. Proof of concept değildir: gate ağları ve çıkış katmanı hâlâ float, yalnız state döngüsü Boolean.

Teori tarafı: `docs/10_teori.md`. **Kod:** `sw/fbseq/`. **Sonuçlar:** `model/fbseq/*.json`.

---

1. Hipotezler ve durum

	Hipotez	Sonuç
H1	Döngü derinliği Fmax'i belirler	**Tuttu.** State'e bağlı her LUT seviyesi Fmax'i ~%25–30 düşürüyor
H2	İfade gücü sıralaması teoriye uyar	**Tuttu.** set/keep → star-free; + toggle → Z_2; 2 bit → Z_3; 3 bit → A5
H3	Döngüsü kısa model gerçek veride rekabetçi	**Kısmen.** Hard-forward ve eğim tavlamasıyla Boolean B pencere modelini geçiyor (1,418 ve 1,453); GRU'nun (1,294) gerisinde
H4	Gate ağları LUT'a çevrilince kalite korunur	**Test edilmedi** (Faz 1)

---

2. Kurulum

Veri. Loghub'ın 16 sistemden 2 000'er satırlık örnekleri (`scripts/get_loghub.sh`). Her dosya satır sınırında %80 train ve %20 val olarak ayrıldı, sonra 256 byte'lık bağımsız paketlere bölündü: 3 482 val paketi, 891 392 byte. Her paket BOS ile başlıyor ve model her pakete sıfır state ile giriyor. Bu, bağımsız paket sıkıştırma senaryosuyla birebir aynı.

Modeller (hepsi ~100K parametre, byte başına 90–97 bin MAC; microgpt 120 bin):

	Model	Döngüde ne var
A	Son W byte üzerinde MLP (W = 8, 16, 32)	Döngü yok
B	Input-gated Boolean recurrence: 2 katman × 120 bit; set/keep, + toggle, 2- ve 3-bitlik bloklar	Bit başına bir mux / LUT6 / 8:1 mux
C	GRU (makemore hücresi)	Hücrenin tamamı
D	microgpt, 4 katman, C = 40	Döngü yok (KV cache bellekte)

Protokol. 3 000 adım, batch 32 × 256 byte, AdamW lr 3e-3, warm-up ve cosine. Cebirsel görevlerde 2 000 adım, batch 64, 64 uzunlukta eğitim, 64 ve 256'da test.

Hardware. Döngü ölçümleri XC7A100T için Yosys + nextpnr-himbaechel ile (`loop_bench.py`, iki seed). Değerler nextpnr'ın timing tahmini; chip'in clock ağı pratikte ~450 MHz civarında sınırlı.

---

3. Sonuçlar

3.1 Döngü derinliği ve Fmax (`loop.json`)

Döngüdeki devre (S = 120 bit)	Fmax (MHz)
tek mux (kb = 1)	516 / 441
4:1 mux (kb = 2, LUT6)	470 / 395
8:1 mux (kb = 3)	378 / 421
state'e bağlı, 1 / 2 / 3 / 4 LUT seviyesi, rastgele bağlantı	366 / 259 / 192 / 154 (ortalama)

Yerellik de önemli: 8 durumlu bloklar (399), rastgele bağlantılı tek seviyeden (366) hızlı.

3.2 Cebirsel görevler (`synth.json`, 3 seed, 256'da doğruluk)

Model	flag	parity	mod 3	A5
A · pencere 8	0,92	0,51	0,35	0,04
B · set/keep	**1,00**	0,51	0,34	0,03
B · + toggle	1,00	**1,00**	0,34	0,03
B · 2-bit blok	1,00	1,00	**1,00**	0,05
B · 3-bit blok	1,00	1,00	1,00	**0,32**
C · GRU	1,00	1,00	1,00	0,59
D · microgpt	0,71	0,55	0,48	0,06

microgpt'nin 64'teki doğrulukları 1,00 / 0,69 / 0,93 / 0,18. 256'daki düşüş ifade gücünden değil, eğitimde görülmeyen pozisyonlardan kaynaklanıyor.

3.3 A5'in gerçekleştirmeleri (`a5_exact.json`, `loop_a5c7.json`, `sat_a5.json`, `loop_a5sat6.json`)

Gerçekleştirme	State	Döngü	Doğruluk	Fmax (MHz)
Öğrenilen 3-bit bloklar (tam tablo)	24	2 seviye	0,32 (eğitimle)	378 / 421
Elle, noktasal 5 × 3 bit	15	LUT5	1,00	424 / 443

Gerçekleştirme	State	Döngü	Doğruluk	Fmax (MHz)
Block-local en küçük: V4 + A4 coset'leri	7	LUT6 / LUT5	1,00	443 / 473
SAT, 6 bit (bilgi alt sınırı)	6	LUT6	1,00	454 / 456

Ayrıntı ve ispatlar: `docs/10_teori.md` §5.

3.4 Byte LM: Loghub, 256 B bağımsız paketler (`bytes.json`, `base.json`)

Yöntem	Ek bilgi (bir kez gönderilir)	bpb
gzip -9	–	5,86
zstd -19	–	5,51
zlib (raw deflate)	–	5,30
zstd -19 + 16 KB sözlük	16 KB	2,34
zstd -19 + 100 KB sözlük	100 KB	1,90
D · microgpt	~100 KB (INT8)	1,917
A · pencere 32	~100 KB	1,604
B · + toggle (soft→hard)	~100 KB	1,593
B · set/keep (soft→hard)	~100 KB	1,583
A · pencere 16	~100 KB	1,457
A · pencere 8	~100 KB	1,453
B · set/keep, hard-forward + eğim tavlaması	~100 KB	**1,418**
C · GRU	~100 KB	**1,294**

Uyarılar:

- LM değerleri ideal kodlama maliyeti. Gerçek range coder paket başına ~2 byte, yani ~+0,06 bpb ekler.
- Modeller float. Gate ağları ve head LUT'a çevrilmedi.
- Test, aynı log dosyalarının son %20'si. Görülmemiş bir sistemde genelleme test edilmedi.
- microgpt bu protokolde yetersiz eğitildi; düşük lr ve uzun eğitimle tekrarlanmalı.
- 2-bit ve 3-bit blok modelleri ilk turda NaN verdi; sebep CPU relaxation'ındaki gradyan patlaması. Düzeltildi, yeniden eğitim sürüyor.

3.5 Soft–hard farkı (`gap.json`)

Model	Soft	Doğrudan hard	Hard'a uyarlanmış	Δ_hard
B · set/keep	**1,398**	2,769	1,583	0,185

Model	Soft	Doğrudan hard	Hard'a uyarlanmış	Δ_hard
B · + toggle	1,408	2,607	1,593	0,185
B · set/keep, pencere 8	1,453	2,425	1,566	0,113
B · + toggle, pencere 8	1,473	2,407	1,590	0,117

- Soft modelin state'leri 0 ve 1'den uzak: ortalama min(s, 1−s) 0,16–0,21.
- D(t), farklı olan bit oranı: birinci katmanda ~%6, ikinci katmanda ~%11–13. t ≈ 8–16'da doyuyor, birikmiyor.
- Pencereyi 8 byte'a çıkarmak hard sonucu değiştirmedi.

3.6 Hard-aware eğitim (`hardaware_bytes.json`, `hardaware_a5.json`)

Loghub (2 seed ortalaması):

Model	softhard	Gumbel-ST	Hard-ST	Hard + eğim tavlaması
B · set/keep	1,568	1,685	1,545	**1,418**
B · + toggle	1,593 (1 seed)	–	1,621	**1,462**

- Belirleyici bileşen eğim tavlaması: backward'da sigmoid(a·l), a 1'den 5'e çıkıyor.
- Gumbel-ST'nin geride kalması, Kim'in (2026) düşük sıcaklık bulgusuyla uyumlu.
- softhard ve Gumbel değerleri ilk turdan; ilk turdaki Hard-ST aslında eğim tavlamasıydı, bu hata düzeltildi.

A5 (B · 3-bit blok, 4 seed, 256'da doğruluk):

Yöntem	Son	En iyi
softhard	1,00 / 0,21 / 1,00 / 0,09	1,00 / 0,36 / 1,00 / 0,25
Hard-ST	0,12 / 0,13 / 0,05 / 0,05	aynı
Hard + eğim tavlaması	0,12 / 0,05 / 0,11 / 0,05	aynı

İki görev ters yönde. Dil modelinde baştan Boolean eğitim en iyisi. Durum izlemede ise soft aşama çözümü keşfetmek için şart: soft→hard koşuların yarısı %100'e ve tam uzunluk genellemesine ulaşıyor, baştan hard koşuların hiçbiri ulaşamıyor. Başarısız seed'ler 1/3 civarındaki coset aşamasında takılıyor; birinde model 0,25'i bulduktan sonra 0,09'a geriliyor.

3.7 GRU'nun bellek ufku (`gru_horizon.json`)

Normal eğitilmiş GRU, değerlendirmede state her k byte'ta sıfırlanarak ölçüldü:

k	8	16	32	64	128	yok
bpb	3,51	2,60	1,95	1,58	1,39	1,294

GRU, 64–128 byte ötesindeki bilgiden de fayda sağlıyor. İki karışık etken var:

- GRU, eğitimde ortadan sıfırlanmayı görmedi.

- Blok halinde sıfırlama, kayan bir pencereyle aynı değil.

Her 8 byte'ta sıfırlanarak eğitilmiş GRU-8 (2,18 bpb) bu yüzden pencere 8 modeliyle karşılaştırılamaz. Temiz deney, kayan pencere GRU'su; sırada.

---

4. Karar

- **H1, H2:** Tuttu.
- **H3 (Loghub):**
- Döngüsü bir mux kadar olan Boolean model, doğru eğitimle aynı bütçedeki pencere modelini geçiyor. Döngü yok ama 8 byte'ın ötesini taşıyan bir state'in işe yaradığını gösteriyor.
- Soft modele kalan fark 0,02 bpb.
- GRU'ya kalan fark 0,12 bpb. Bunun ne kadarının input-gated yapının ifade sınırından, ne kadarının eğitimden geldiği açık.
- **Öğrenilebilirlik:**
- Discretization farkı dil modelinde büyük ölçüde kapandı.
- Durum izleme görevinde keşif sorunu kaldı. Teori belgesinin learnability bölümünün odağı bu.
- **Sıkıştırma case'i ayakta:**
- GRU, 100 KB sözlüklü zstd'den %32 daha az bit harcıyor;
- Boolean B %25 daha az bit harcıyor.

---

5. Sonraki adımlar

1. Transition codebook (`codebook.py`): A5'te ve Loghub'da, iki eğitim yöntemiyle. Çalışıyor.
2. 2-bit ve 3-bit blokların düzeltilmiş relaxation'la Loghub sonucu. Çalışıyor.
3. microgpt için adil eğitim (düşük lr, uzun eğitim) ve kayan pencere GRU'su.
4. Kararlılık: tek bit çevirme deneyi ve head'in Lipschitz sabiti.
5. Faz 1:
6. gate ağlarını ve head'i LUT ağlarına çevirmek;
7. bit bit olasılık head'i ve range coder ile gerçek sıkıştırma;
8. bir sistemi tamamen dışarıda bırakarak (leave-one-system-out) genelleme testi.