Faz 0: geri besleme kısıtlı sequence modellerin fizibilitesi

Soru. FPGA'nin boş duran logic kapasitesini kullanarak, döngüsü çok kısa olan öğrenilmiş bir dijital sekans makinesi, aritmetik ağırlıklı bir dil modelinin yerini tutabilir mi? Faz 0 bu fikrin denemeye değip değmediğini ölçer. Proof of concept değildir: gate ağları ve çıkış katmanı hâlâ float, yalnız state döngüsü Boolean.

Teori tarafı: `docs/10_teori.md`. **Kod:** `sw/fbseq/`. **Sonuçlar:** `model/fbseq/*.json`.

---

1. Hipotezler ve durum

	Hipotez	Sonuç
H1	Döngü derinliği Fmax'i belirler	**Tuttu.** State'e bağlı her LUT seviyesi Fmax'i ~%15–35 düşürüyor; yerel tek seviyeli döngüler ~670–700 MHz (29 Ekim'de düzeltilmiş ölçüm düzeneğiyle)
H2	İfade gücü sıralaması teoriye uyar	**Tuttu.** set/keep → star-free; + toggle → Z_2; 2 bit → Z_3; 3 bit → A5
H3	Döngüsü kısa model gerçek veride rekabetçi	**Kısmen.** Hard-forward ve eğim tavlamasıyla Boolean B pencere modelini geçiyor (1,418 ve 1,453); GRU'nun (1,294) gerisinde
H4	Gate ağları LUT'a çevrilince kalite korunur	**Test edilmedi** (Faz 1)

---

2. Kurulum

Veri. Loghub'ın 16 sistemden 2 000'er satırlık örnekleri (`scripts/get_loghub.sh`). Her dosya satır sınırında %80 train ve %20 val olarak ayrıldı, sonra 256 byte'lık bağımsız paketlere bölündü: 3 482 val paketi, 891 392 byte. Her paket BOS ile başlıyor ve model her pakete sıfır state ile giriyor. Bu, bağımsız paket sıkıştırma senaryosuyla birebir aynı.

Modeller (hepsi ~100K parametre, byte başına 90–97 bin MAC; microgpt 120 bin):

	Model	Döngüde ne var
A	Son W byte üzerinde MLP (W = 8, 16, 32)	Döngü yok
B	Input-gated Boolean recurrence: 2 katman × 120 bit; set/keep, + toggle, 2- ve 3-bitlik bloklar	Bit başına bir mux / LUT6 / 8:1 mux
C	GRU (makemore hücresi)	Hücrenin tamamı

	Model	Döngüde ne var
D	microgpt, 4 katman, C = 40	Döngü yok (KV cache bellekte)

Protokol. 3 000 adım, batch 32 × 256 byte, AdamW lr 3e-3, warm-up ve cosine. Cebirsel görevlerde 2 000 adım, batch 64, 64 uzunlukta eğitim, 64 ve 256'da test.

Hardware. Döngü ölçümleri XC7A100T için Yosys + nextpnr-himbaechel ile (`loop_bench.py`, iki seed). Değerler nextpnr'ın timing tahmini; chip'in clock ağı pratikte ~450 MHz civarında sınırlı.

---

3. Sonuçlar

3.1 Döngü derinliği ve Fmax (`loop.json`)

Döngüdeki devre (S = 120 bit)	Kritik yoldaki mantık	Fmax (MHz, iki seed)
tek mux (kb = 1)	1 LUT	667 / 669
4:1 mux (kb = 2, LUT6)	1 LUT	708 / 681
8:1 mux (kb = 3)	2 LUT	482 / 490
state'e bağlı, 1 / 2 / 3 / 4 LUT seviyesi, rastgele bağlantı	1 / 2 / 3 / 4 LUT	378 / 238 / 175 / 151 (ortalama)

Ölçüm düzeltmesi (29 Ekim). İlk ölçümlerde state, LED'e iki aşamalı bir XOR ağacıyla indirgeniyordu; ikinci aşama 2–3 LUT derinliğindeydi. Tek seviyeli döngülerde (mux1, mux4, mux8 ve bütün A5 gerçekleştirmeleri) kritik yol döngü değil bu ağaçtı. Eski değerler (516/441, 470/395, 378/421, A5 için 424–473) döngünün değil düzeneğin sınırıydı. Düzenek her LUT'tan sonra register'lanacak biçimde değiştirildi; artık döngü dışındaki her yol tek LUT. Her sonuçla birlikte kritik yolun mantığı ve başlangıç neti de kaydediliyor (`loop_bench.critical_path`). dep1–dep4 zaten döngüyü ölçüyordu; değerleri değişmedi.

Yerellik çok belirleyici: yerel 2 seviyeli 8:1 mux (486), rastgele bağlantılı **tek** seviyeden (378) hızlı. Yönlendirme, gecikmenin büyük kısmı.

3.2 Cebirsel görevler (`synth.json`, 3 seed, 256'da doğruluk)

Model	flag	parity	mod 3	A5
A · pencere 8	0,92	0,51	0,35	0,04
B · set/keep	**1,00**	0,51	0,34	0,03
B · + toggle	1,00	**1,00**	0,34	0,03
B · 2-bit blok	1,00	1,00	**1,00**	0,05
B · 3-bit blok	1,00	1,00	1,00	**0,32**
C · GRU	1,00	1,00	1,00	0,59

Model	flag	parity	mod 3	A5
D · microgpt	0,71	0,55	0,48	0,06

microgpt'nin 64'teki doğrulukları 1,00 / 0,69 / 0,93 / 0,18. 256'daki düşüş ifade gücünden değil, eğitimde görülmeyen pozisyonlardan kaynaklanıyor.

3.3 A5'in gerçekleştirmeleri (`a5_exact.json`, `loop_a5c7.json`, `sat_a5.json`, `loop_a5sat6.json`)

Gerçekleştirme	State	Döngü	Doğruluk	Fmax (MHz)
Öğrenilen 3-bit bloklar (tam tablo)	24	2 seviye	0,32 (eğitimle)	482 / 490
Elle, ters kod $r = p^{-1}$, 5 × 3 bit	15	LUT5	1,00	651 / 724
Block-local en küçük: V4 + A4 coset'leri	7	LUT6 / LUT5	1,00	638 / 589
SAT, 6 bit (bilgi alt sınırı)	6	LUT6	1,00	665 / 622

Fmax değerleri düzeltilmiş düzenekle (§3.1).

Ayrıntı ve ispatlar: `docs/10_teori.md` §5.

3.4 Byte LM: Loghub, 256 B bağımsız paketler (`bytes.json`, `base.json`)

Yöntem	Ek bilgi (bir kez gönderilir)	bpb
gzip -9	–	5,86
zstd -19	–	5,51
zlib (raw deflate)	–	5,30
zstd -19 + 16 KB sözlük	16 KB	2,34
zstd -19 + 100 KB sözlük	100 KB	1,90
D · microgpt	~100 KB (INT8)	1,917
A · pencere 32	~100 KB	1,604
B · + toggle (soft→hard)	~100 KB	1,593
B · set/keep (soft→hard)	~100 KB	1,583
A · pencere 16	~100 KB	1,457
A · pencere 8	~100 KB	1,453
B · set/keep, hard-forward + eğim tavlaması	~100 KB	**1,418**
C · GRU	~100 KB	**1,294**

Uyarılar:

- LM değerleri ideal kodlama maliyeti. Gerçek range coder paket başına ~2 byte, yani ~+0,06 bpb ekler (tahmin).
- **zstd değerleri gerçek dosya boyutu ve frame başlığını içeriyor.** 256 byte'lık her paket için zstd 10 byte başlık yazıyor: magic 4, frame header 1, içerik boyu 2, blok başlığı 3 (`zstd -19 --no-check` ile ölçüldü). 100 KB sözlüklü satırda bu ~0,31 bpb ediyor. Eşit koşullu karşılaştırma aşağıda (§4).
- Modeller float. Gate ağları ve head LUT'a çevrilmedi.
- Test, aynı log dosyalarının son %20'si. Görülmemiş bir sistemde genelleme test edilmedi.
- microgpt bu protokolde yetersiz eğitildi; düşük lr ve uzun eğitimle tekrarlanmalı.
- 2-bit ve 3-bit blok modelleri ilk turda NaN verdi; sebep CPU relaxation'ındaki gradyan patlaması. Düzeltilmiş relaxation ve eğim tavlamasıyla 1,680 ve 2,237 (1 seed; §3.6).

3.5 Soft–hard farkı (`gap.json`)

Model	Soft	Aynı ağırlıkla hard	Hard'a uyarlanmış	Uyarlanmış ağırlıkla soft	Performans açığı (uyarlanmış hard − soft)
B · set/keep	**1,398**	2,769	1,583	1,817	0,185
B · + toggle	1,408	2,607	1,593	1,776	0,184
B · set/keep, pencere 8	1,453	2,425	1,566	1,778	0,113
B · + toggle, pencere 8	1,473	2,407	1,590	1,774	0,117

İki ölçü ayrı tutulmalı (denetimden sonra düzeltildi):

- **Aynı parametrede discretization farkı**, Δ_disc(θ) = L_hard(θ) − L_soft(θ). Set/keep'te soft eğitimden sonra +1,372, hard uyarlamadan sonra −0,234. Model hangi forward'la eğitildiyse onda iyi, diğerinde kötü.
- **Son sütun** farklı parametre noktalarını karşılaştırıyor. Önceki sürümde Δ_hard adıyla discretization farkı gibi sunulmuştu.
- Soft modelin state'leri 0 ve 1'den uzak: ortalama min(s, 1−s) 0,16–0,21.
- D(t), farklı olan bit oranı: birinci katmanda ~%6, ikinci katmanda ~%11–13. t ≈ 8–16'da doyuyor, birikmiyor.
- Pencereyi 8 byte'a çıkarmak hard sonucu değiştirmedi.

3.6 Hard-aware eğitim (`hardaware_bytes.json`, `hardaware_a5.json`)

Loghub (2 seed ortalaması):

Model	softhard	Gumbel-ST	Hard-ST	Hard + eğim tavlaması
B · set/keep	1,568	1,685	1,545	**1,418**
B · + toggle	1,593 (1 seed)	–	1,621	**1,462**
B · 2-bit blok	–	–	–	1,680 (1 seed)

Model	softhard	Gumbel-ST	Hard-ST	Hard + eğim tavlaması
B · 3-bit blok	–	–	–	2,237 (1 seed)

- Belirleyici bileşen eğim tavlaması: backward'da sigmoid(a·l), a 1'den 5'e çıkıyor.
- Gumbel-ST'nin geride kalması, Kim'in (2026) düşük sıcaklık bulgusuyla uyumlu.
- softhard ve Gumbel değerleri ilk turdan: `model/fbseq/archive/hardaware_bytes_run1.json`. İlk turdaki Hard-ST aslında eğim tavlamasıydı; bu hata düzeltildi ve Hard-ST yeniden koşuldu. Gumbel'in surrogate ölçeği 1/τ olduğundan bu hatadan etkilenmedi; düzeltilmiş kodla yeniden üretildi ve birebir aynı çıktı (1,6905 / 1,6799).
- Bloklarda sıralama ifade gücünün tersine: set/keep 1,418 < toggle 1,462 < 2-bit 1,680 < 3-bit 2,237. Eşit parametre bütçesinde gate ağı daralıyor (gizli genişlik 80 → 48 → 26) ve tablolar büyüyor. Bu iki etken ayrılmadan "log verisi grup benzeri state istemiyor" denemez.

A5 (B · 3-bit blok, 4 seed, 256'da doğruluk):

Yöntem	Son	En iyi
softhard	1,00 / 0,21 / 1,00 / 0,09	1,00 / 0,36 / 1,00 / 0,25
Hard-ST	0,12 / 0,13 / 0,05 / 0,05	aynı
Hard + eğim tavlaması	0,12 / 0,05 / 0,11 / 0,05	aynı

İki görev ters yönde, denenen reçetelerle. Dil modelinde baştan Boolean eğitim en iyisi. A5'te softhard 4 koşunun 2'sinde test edilen 64 ve 256 uzunlukta %100; iki hard-forward yöntemin 8 koşusunun hiçbiri başarılı değil. Başka reçetelerin başarısız olacağı gösterilmedi; "soft aşama şart" denemez.

Başarısız iki softhard koşusu farklı: biri en iyi 0,36'dan 0,21'e, diğeri 0,25'ten 0,09'a geriliyor. "Coset aşamasında takılma" (Zhang & Li 2026) yalnız bir hipotez; doğruluk sayısı iç temsili göstermez.

3.7 GRU'nun bellek ufku (`gru_horizon.json`)

Normal eğitilmiş GRU, değerlendirmede state her k byte'ta sıfırlanarak ölçüldü:

k	8	16	32	64	128	yok
bpb	3,51	2,60	1,95	1,58	1,39	1,294

GRU, 64–128 byte ötesindeki bilgiden de fayda sağlıyor. İki karışık etken var:

- GRU, eğitimde ortadan sıfırlanmayı görmedi.
- Blok halinde sıfırlama, kayan bir pencereyle aynı değil.

Her 8 byte'ta sıfırlanarak eğitilmiş GRU-8 (2,18 bpb) bu yüzden pencere 8 modeliyle karşılaştırılamaz. Temiz deney, kayan pencere GRU'su; sırada.

---

4. Karar

- **H1, H2:** Tuttu.
- **H3 (Loghub):**
- Döngüsü bir mux kadar olan Boolean model, doğru eğitimle aynı bütçedeki pencere modelini geçiyor. Döngü yok ama 8 byte'ın ötesini taşıyan bir state'in işe yaradığını gösteriyor.
- Eski soft referansa (1,398) açık 0,02 bpb. Bu farklı eğitimlerin karşılaştırması; aynı parametrede discretization farkı değil.
- Kapsam: iki seed, test aynı dosyaların son %20'si.
- GRU'ya kalan fark 0,12 bpb. Bunun ne kadarının input-gated yapının ifade sınırından, ne kadarının eğitimden geldiği açık.
- **Öğrenilebilirlik:**
- Hard modelin soft referansa göre performans açığı dil modelinde büyük ölçüde kapandı.
- Durum izleme görevinde keşif sorunu kaldı. Teori belgesinin learnability bölümünün odağı bu.
- **Sıkıştırma case'i ayakta, ama avantaj ilk yazılandan küçük.** Önceki sürüm, ideal LM kod uzunluğunu zstd'nin başlıklı gerçek dosya boyutuyla karşılaştırıyordu ve %32 / %25 diyordu. Eşit koşullu karşılaştırma için LM'ye coder sonlandırması eklendi (paket başına ~2 byte, tahmin). zstd'den ise başlığın çıkarılabilir kısmı düşüldü:

zstd + 100 KB sözlük	bpb	B (1,418 + 0,0625)	GRU (1,294 + 0,0625)
Başlıklı, ölçülen	1,902	%22 daha az	%29 daha az
Magic ve içerik boyu yok (kütüphane API'si ile mümkün)	1,715	%14	%21
Yalnız sıkıştırılmış içerik (alt sınır)	1,590	%7	%15

Gerçekçi aralık B için %7–14, GRU için %15–21. Henüz hesaba katılmayanlar: model ağırlıklarının aktarımı (100K parametre; INT8'de ~100 KB, sözlükle aynı ölçek ama INT8 kalitesi test edilmedi), olasılık nicemlemesi ve gerçek bir range coder. Kesin karşılaştırma Faz 1'de, bit-exact encode/decode ile yapılacak.

---

5. Sonraki adımlar

1. Transition codebook (`codebook.py`): **olumsuz sonuç.** A5'te 24 koşunun en iyisi 0,12 (üç başlangıç × iki yöntem × 4 seed); Loghub 2,07–2,16 bpb. Ayrıntı `docs/10_teori.md` §7.
2. 2-bit ve 3-bit bloklar Loghub'da set/keep'in gerisinde (1,680 / 2,237). Sıradaki: gate genişliği sabit tutularak tekrar ya da set/keep + küçük blok karışımı.
3. microgpt için adil eğitim (düşük lr, uzun eğitim) ve kayan pencere GRU'su.
4. Kararlılık: tek bit çevirme deneyi ve head'in Lipschitz sabiti.
5. Faz 1:
6. gate ağlarını ve head'i LUT ağlarına çevirmek;
7. bit bit olasılık head'i ve range coder ile gerçek sıkıştırma;
8. bir sistemi tamamen dışarıda bırakarak (leave-one-system-out) genelleme testi.