İlerleme raporu: case arayışından geri besleme kısıtlı sıralı hesaplamaya

Kapsam. 27–28 Ekim 2026 arasında yapılanlar. Başlangıç noktası, hocanın "bu proje hangi problemi çözüyor?" sorusu ve bunun sonucunda araştırmanın "modeli FPGA'ye sığdırmak" yerine "modeli FPGA'nin fiziksel kısıtlarından türetmek" yönüne dönmesi.

İlgili belgeler:

- `docs/08_case_arastirmasi.pdf`: case araştırması;
- `docs/09_faz0.pdf`: Faz 0 sonuçları;
- `docs/10_teori.pdf`: teori çerçevesi.

Kod ve sonuçlar: `sw/fbseq/`, `model/fbseq/*.json`, `scripts/`.

---

1. Tek bakışta

	Durum
Hocanın case sorusu	**Cevaplandı:** deterministik dil modeliyle kayıpsız telemetri ve log sıkıştırma; yan case olarak aynı modelle anomali tespiti
Yeni araştırma yönü	**Belirlendi:** geri besleme kısıtlı (feedback-constrained) sıralı hesaplama. Döngüdeki mantık derinliği tasarımın merkez değişkeni
Faz 0 (fizibilite)	**Büyük ölçüde tamam:** 4 hipotezden ikisi tuttu, biri kısmen tuttu, biri Faz 1'e kaldı
İlk teori sonucu	**Var:** A5 için tek LUT seviyesinde en az state, sıkı biçimde 6 bit (SAT tanığı ve bilgi alt sınırı)
Gerçek veride kalite	Boolean model, doğru eğitimle pencere modelini geçiyor. 100 KB sözlüklü zstd'den %25 daha az bit harcıyor; GRU %32
Literatürdeki konum	Üç hatlı tarama yapıldı; rakipler ve boşluklar belirlendi
Çalışmakta	Transition codebook (A5 ve Loghub), 2-bit ve 3-bit bloklarla Loghub

---

2. Kronoloji

2.1 Hız sorusunun cevabı: CPU baseline

- Karpathy'nin `run.c`'si, stories260K'yı kartla aynı koşulda çalıştırdı: Apple M1, tek thread, 256 token, greedy. `make cpu-baseline`; `model/zoo/cpu_baseline.json`.
- Sonuç:

Platform	token/s	Token başına cycle
M1, -Ofast	14 397	~222 bin
M1, -O3	6 718	–
FPGA, 25 MHz	496	50 397

CPU mutlak hızda 29 kat önde; token başına cycle'da FPGA 4,4 kat verimli.

- Sunuma eklendi: slayt 2 ("dört soru, dört cevap") ve yeni slayt 46 (kaybın kaynağı ve CPU karşılaştırması). Commit `bee67be`.

2.2 Case araştırması (`docs/08`, commit `9f6939a`)

Dört paralel araştırma (sıkıştırma, CAN bus, sertifikasyon, rakip platformlar) ve bir puanlama matrisi:

- **Ana case: kayıpsız sıkıştırma.** Arithmetic coding'de encoder ve decoder olasılığı bit bit aynı hesaplamak zorunda. Float modeller bunu farklı donanımlarda garanti edemiyor (Ballé 2019, llama-zip, NNCP v2). Bizim bit-exact integer engine'imiz bunu yapısı gereği sağlıyor.
- **Yan case: anomali tespiti.** –log p hem kodlama maliyeti hem anomali skoru olduğu için aynı model iki işi birden yapıyor (telemetri ya da CAN bus).
- **Çapraz gereksinim: sertifikalanabilirlik.** EASA AI rehberi FPGA'yi mevcut sertifikasyon yolunun içinde sayıyor, GPU'yu kapsam dışında bırakıyor.
- **Dürüst konumlandırma.** Ham hızda ve enerjide üstünlük iddia edemiyoruz. MCU'lara göre 5–26 kat hızlıyız.

2.3 Yön tartışması

Hocanın yönü, iki ayrı yorum metni üzerinden tartışıldı. Kendi ölçümlerimiz yönü belirledi:

- **BRAM darboğaz:** stories260K'da %72; iki model RAMB18 parçalanması yüzünden place edilemedi.
- **Logic kaynakları boş:** LUT bel'lerinin en fazla %31'i kullanılıyor, DSP hiç kullanılmıyor.
- **Kritik yol:** gecikmenin %73'ü routing.

Bunun sonucunda:

- **Memory-centric model elendi**, çünkü BRAM zaten dolu.
- **Logic-native yön seçildi:** boş duran logic kaynağını kullanmak.
- **"Neden recurrent?" sorusunun cevabı:** belirleyici olan recurrence değil, loop-carried dependency'nin derinliği. Döngüsü bir mux kadar olan, geri kalanı pipeline'lanan bir yapı hedeflendi. Encoder tarafında girdinin tamamı baştan bilindiği için paralellik mümkün.
- **Dört aday:**
- A: pencereli feedforward;
- B: input-gated Boolean recurrence (set/keep, toggle, 2- ve 3-bitlik bloklar);
- C: GRU;
- D: microgpt.
- **Teorinin önerdiği tasarım:** transition codebook. Her blok, keyfi bir tablo yerine m öğrenilmiş dönüşümden birini seçiyor; döngüde her bit için tek bir LUT(kb + $\log_2$m) kalıyor.

2.4 Faz 0 altyapısı (commit 985fbba)

- **sw/fbseq/fbseq.py (CPU):** dört aday, cebirsel görevler (flag, parity, mod 3, A5), Loghub byte LM, klasik sıkıştırıcı baseline'ları (gzip, xz, zstd, zstd + sözlük).
- **sw/fbseq/fbseq_gpu.py:** aynı modeller, B için associative scan, cuDNN GRU, paralel işler. Mac'te test edildi.
- **scripts/colab_faz0.sh:** Colab'da tek komutluk çalıştırma. Kullanıcının hesabına A100 yerine T4 düştü. Küçük modellerde T4, M1'den belirgin hızlı değil; tek istisna GRU (~2 kat).
- **Colab CLI** (`google-colab-cli 0.7.5`) kuruldu ve giriş yapıldı.
- Tarayıcıdaki runtime'a bağlanamıyor; CLI yalnız kendi açtığı runtime'ları yönetebiliyor.
- Hesapta 0 compute unit var; A100 açılmadı.
- **sw/fbseq/loop_bench.py:** döngü devrelerini Yosys + nextpnr ile place edip Fmax ölçüyor.

2.5 Faz 0 deneyleri

Ayrıntı `docs/09_faz0.md`'de; özet:

1. **Döngü derinliği** (`loop.json`): tek mux 478, 4:1 mux 432, 8:1 mux 399 MHz. State'e bağlı 1/2/3/4 seviye: 366 / 259 / 192 / 154 MHz. **H1 tuttu.**
2. **Cebirsel görevler** (`synth.json`, 3 seed): set/keep → flag; + toggle → parity; 2 bit → mod 3; 3 bit → A5'te 0,32. Sıralama teoriyle bire bir. **H2 tuttu.**
3. **Byte LM** (`bytes.json`, `base.json`, Loghub, 256 B bağımsız paket):

Model	bpb
GRU	**1,294**
Pencere 8	1,453
B · set/keep (soft→hard)	1,583
zstd + 100 KB sözlük	1,90
zstd, sözlüksüz	5,51
microgpt	1,917 (bu protokolde yetersiz eğitim)

1. **Soft–hard farkı** (`gap.json`):
2. B'nin soft hali 1,398; pencere modelini geçiyor.
3. Doğrudan hard 2,77; uyarlanmış hard 1,583; Δ_hard = 0,185.
4. Soft state'ler 0 ve 1'den uzak.
5. D(t), farklı bit oranı: %6 ile %12 arasında; t ≈ 8–16'da doyuyor.
6. **GRU bellek ufku** (`gru_horizon.json`): 128 byte'ta sıfırlama 1,39, 64'te 1,58. 64–128 byte ötesindeki bilgi işe yarıyor; ölçümde karışık etkenler var (§5).
7. **Hard-aware eğitim** (`hardaware_*.json`):
8. **Loghub:** baştan Boolean forward ve eğim tavlamasıyla **1,418** (pencere 8: 1,453; soft: 1,398). Sade Hard-ST 1,545, Gumbel-ST 1,685. **H3 kısmen tuttu.**
9. **A5:** soft→hard seed'lerin yarısı %100; baştan hard 8 koşunun hiçbiri 0,13'ü geçmiyor.
10. **Ödünleşim:** keşif ile uyum. Dil modelinde baştan Boolean, durum izlemede soft aşama gerekiyor.

2.6 Teori (`docs/10_teori.md`; commit'ler `1c348ab`, `f45da5e`)

- **Biçimsel model:** K-LUT recurrent devre, block-local yapı, maliyet dörtlüsü (S, D, L, R).
- **Bilinen ve atıflı:** cascade'in iteration bound'u (Leiserson–Saxe, Thm 11), grup word problem'leri için encoding'ler, Myhill–Nerode alt sınırı.
- **Bizim sonuçlarımız (A5 küçük vakası):**

Gerçekleştirme	State	Döngü	Fmax (MHz)
Öğrenilen, tam tablolu 3-bit bloklar	24	2 seviye	399
Elle, noktasal	15	LUT5	433
Block-local en küçük (V4 + A4 coset'leri; K = 5'te 9 bit; K = 4'te imkânsız)	7	LUT6	458
SAT, alt sınırda	**6**	LUT6	455

İspat yolu: Hartmanis–Stearns SP partition'ları, grup makinelerinde alt grupların coset'lerine karşılık gelir; injectivity ⇔ alt grupların kesişimi birim eleman; A5'in 59 alt grubu tarandı. Kod: `sw/fbseq/theory_sat.py`.

- **Kararlılık:**
- hata rekürsiyonu sınırı ve koşullu beklenen değer sınırı;
- tek bit için $\mathbb{F}_2$ tam eşitliği;
- bloklara genelleme: birleşen map'ler farkı siler, permütasyonlar korur;
- kayba bağlantı (Lipschitz sınırı);
- **bellek ile dayanıklılık aynı mekanizmaya bağlı.**
- **Sanı** (literatür ajanının taslağı, kontrol edilmeli): k-bitlik bloklar tam olarak, sözdizimsel monoidinin basit grup bölenleri S_{2^k}'yi bölen dilleri tanır. Test edilebilir öngörüleri var.

2.7 Literatür taraması (üç hat)

Klasik:

- Leiserson–Saxe 1991; Lin–Messerschmitt 1991 (FSM look-ahead);
- Stearns–Hartmanis 1961 (partition pair: Teorem C'nin çekirdeği);
- Derby 2001 (CRC state-space dönüşümü: doğrusal durum; doğrusal olmayan genellemesi bulunamadı);
- Barkalov 2021 (LUT tabanlı FSM);
- Shende 2003 (parity engeli).

İfade gücü: Sarrof 2024, Grazzi 2025, Merrill 2024, PD-SSM 2025 (en yakın nöral akraba), Knorozova & Ronca 2024, Zhang & Li 2026 (0,32'nin teşhisi: coset aşaması).

Logic ağları:

- RDDLGN (EdgeFM 2025 atölyesi): keep yolu yok, donanım yok.
- Gating LGN (NeurIPS 2026 AXIOM atölyesi): bit başına keep/write mux, donanım yok.

- Mind the Gap 2025, Kim 2026 (Hard-ST ve CAGE), HM-RNN 2017.

Bulunamayanlar (bizim için boşluklar):

- sentezlenmiş bir recurrent logic ya da LUT modeli ve Fmax'i;
- logic veya LUT ağlarıyla byte düzeyinde bpb;
- döngü derinliğini tasarım kısıtı yapan bir çalışma;
- Boolean transition codebook;
- adım bazında discretization gap ölçümü;
- LUT fan-in kısıtlı en küçük grup gerçekleştirmeleri.

---

3. Bugün ne iddia edebiliriz, neyi edemeyiz?

Edebiliriz:

1. Döngüdeki mantık derinliği ile Fmax arasındaki ilişkiyi XC7A100T'de ölçtük.
2. Boolean blok recurrence'ın ifade gücü sıralaması teoriyle örtüşüyor; ölçtük.
3. A5 için tek seviyeli fan-in 6 gerçekleştirmenin en küçük state'i tam olarak 6 bit; block-local kısıtla 7 bit. Hepsi doğrulanmış ve place edilmiş.
4. Gerçek log verisinde Boolean recurrence, doğru eğitimle aynı bütçedeki pencere modelini ve sözlüklü zstd'yi geçiyor. Bu ideal bit maliyeti; model float.
5. Soft–hard farkı ve adım bazında state ayrışması ölçüldü. Hard-forward ve eğim tavlaması bu farkı büyük ölçüde kapatıyor.

Edemeyiz (henüz):

1. Gate ağları ve olasılık head'i float. Model bütünüyle bir LUT devresi değil (H4, Faz 1).
2. Gerçek sıkıştırma yok: range coder ve bit-exact encode/decode yapılmadı.
3. Görülmemiş log sistemlerine genelleme test edilmedi.
4. Bütün donanım sonuçları simülasyon ve STA'ya dayanıyor; enerji ölçülmedi.
5. A5'in eğitimle güvenilir biçimde öğrenilmesi çözülmedi (seed'lerin yarısı).
6. Teoride yeni olan yalnız A5 küçük vakası; genel teorem (Problem C) açık.

---

4. Q1 açısından değerlendirme

- **Yeni ve savunulabilir bir çekirdek oluştu:** ifade gücü, encoding, döngü maliyeti ve fiziksel maliyet arasındaki ilişki; ölçülmüş FPGA karşılığı ve gerçek bir uygulama (sıkıştırma) ile birlikte.
- **Henüz eksik:**
- genel bir teorem (A5'in ötesi);
- Boolean devreleri güvenilir biçimde eğiten bir yöntem;
- LUT'a çevrilmiş tam model.
- **Değerlendirme:** Bugün sağlam bir bitirme ve iyi bir konferans çalışması düzeyindeyiz. Q1 için bu üç eksikten en az ikisinin kapanması gerekiyor.

---

5. Hatalar, düzeltmeler ve sınırlar (şeffaflık için)

Konu	Ne oldu	Durum
"A5 için en az iki LUT seviyesi gerekir" iddiası	Yanlıştı; A5 tek seviyede (LUT5) gerçekleştirilebiliyor	Düzeltildi
"Büyük basit grup → derin döngü" alt sınır sanısı	Genel olarak yanlış; one-hot encoding ile her basit grup fan-in 5'te	Karşı örnek belgelendi
"B'nin geride kalmasının sebebi mimari değil"	Erken bir iddiaydı; soft model aynı fonksiyon sınıfında değil	Düzeltildi
hardst yöntemi	Yanlışlıkla eğim tavlaması kullanıyordu	Düzeltildi, yeniden koşuldu
kb ≥ 2 bloklarda NaN	Bit bit multilinear relaxation'ın Jacobian'ı 1'den büyük; gradyan patladı	Kararlı dağılım formuna geçildi; CPU ve GPU soft ve hard eşit
microgpt 1,917	Aynı protokol bir transformer için yetersiz	Adil eğitim yapılacak
GRU bellek ufku	Eğitim/değerlendirme uyumsuzluğu; blok sıfırlama ≠ kayan pencere	Kayan pencere GRU'su yapılacak
T4 hızlanması	Küçük modellerde beklenen hızlanma yok	Kayıt altında
Araştırma ajanı	Kullanıcının derlediği `run.c` binary'lerini kendiliğinden çalıştırdı; repoya yazmadı	Kullanıcıya bildirildi
PDF oluşturucu	Chrome 156 PDF'i yazdıktan sonra hata koduyla çıkıyor	Dosyanın varlığı kontrol ediliyor
Veri	Loghub küçük; test, aynı dosyaların son %20'si	Leave-one-system-out yapılacak

6. Çalışan ve sıradaki işler

Çalışıyor:

- transition codebook: A5'te (softhard ve eğim tavlaması, 4 seed) ve Loghub'da (eğim tavlaması, 2 seed);
- 2-bit ve 3-bit bloklar, eğim tavlamasıyla Loghub'da.

Öncelik sırasıyla sıradakiler:

1. Codebook sonuçları: aynı ifade gücü daha kısa döngüyle, öğrenilebilir mi?
2. A5'i güvenilir öğrenmek: PD-SSM reçetesi, CAGE, curriculum; amaç seed başarı oranını %50'den yukarı çekmek.
3. Problem C'nin genelleşmesi:
4. K = 5 ve K = 4 için block-local olmayan SAT;
5. S_4, mod 5, mod 7 görevleriyle sanının testi;
6. β_K ölçüsünün diğer gruplarda hesaplanması.
7. Kararlılık: tek bit çevirme deneyi ve head'in Lipschitz sabiti.
8. Faz 1:
9. gate ağlarını ve head'i LUT ağlarına çevirmek;
10. bit bit olasılık head'i ve range coder ile gerçek sıkıştırma;
11. leave-one-system-out değerlendirme;
12. adil microgpt eğitimi ve kayan pencere GRU'su.

---

7. Dosya ve commit dizini

Commit	İçerik
`bee67be`	CPU baseline, sunum slayt 2 ve 46
`9f6939a`	Case araştırması (`docs/08`)
`985fbba`	`sw/fbseq` altyapısı, GPU sürümü, Colab script'i, döngü ölçümleri, baseline'lar
`1c348ab`	Teori belgesi, A5 gerçekleştirmeleri, SAT, soft–hard deneyi, kararlı relaxation
`f45da5e`	Faz 0 belgesi, düzeltilmiş hard-aware sonuçları, codebook modeli

Dosya	Görev
`sw/fbseq/fbseq.py`	Modeller, görevler, Loghub, baseline'lar (CPU)
`sw/fbseq/fbseq_gpu.py`	GPU sürümü, scan == döngü kontrolü
`sw/fbseq/loop_bench.py`	Döngü devrelerinin Fmax'i
`sw/fbseq/controls.py`	Soft–hard, A5 elle çözüm, maliyet, bellek ufku
`sw/fbseq/hardaware.py`	Hard-forward eğitim yöntemleri
`sw/fbseq/theory_sat.py`	A5 alt grupları, block-local minimum, SAT
`sw/fbseq/codebook.py`	Transition codebook
`scripts/get_loghub.sh`, `scripts/colab_faz0.sh`, `scripts/cpu_baseline.sh`	Veri, Colab, CPU baseline

Dosya	Görev
`model/fbseq/*.json`	Bütün sonuçlar